

Лекция 14

МНК для множественной регрессии.

Свойства МНК.

Коэффициент детерминации.

Качественные признаки в уравнении регрессии.


Напоминка: МНК для парной регрессии - I

Имеются данные $(X_1, Y_1), \dots, (X_n, Y_n)$, которые мы желаем представить в виде

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i.$$

Задача о наименьших квадратах. Найдите значения β_1 и β_2 , при которых сумма квадратов отклонений значений объясняемой величины Y_i от значений линейной функции $\beta_1 + \beta_2 X_i$ минимальна.

$$\sum_{i=1}^n (Y_i - (\beta_1 + \beta_2 X_i))^2 \xrightarrow{\beta_1, \beta_2} \min.$$



Напоминалка: МНК для парной регрессии - II

Имеются данные $(X_1, Y_1), \dots, (X_n, Y_n)$, которые мы желаем представить в виде

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i.$$

Мы нашли оценки метода наименьших квадратов $\hat{\beta}_1$ и $\hat{\beta}_2$:

$$\begin{cases} \hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}; \\ \hat{\beta}_2 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}. \end{cases}$$

Получили оценённое уравнение регрессии $\hat{Y} = \hat{\beta}_1 + \hat{\beta}_2 X$.

Для всех наблюдений в выборке мы можем рассчитать прогнозные (модельные) значения:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i.$$

Остатки (residuals):

$$e_i = Y_i - \hat{Y}_i.$$


Напоминалка: МНК для парной регрессии - III

Рассмотрим векторы

$$\underset{(n \times 1)}{\underbrace{y}} = \begin{pmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_n \end{pmatrix}; \underset{(n \times 1)}{\underbrace{i}} = \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}; \underset{(n \times 1)}{\underbrace{x}} = \begin{pmatrix} X_1 \\ X_2 \\ \dots \\ X_n \end{pmatrix}; \underset{(n \times 1)}{\underbrace{\hat{y}}} = \begin{pmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \dots \\ \hat{Y}_n \end{pmatrix} = \hat{\beta}_1 i + \hat{\beta}_2 x; \underset{(n \times 1)}{\underbrace{e}} = y - \hat{y}.$$

$$\begin{cases} i'e = 0; \\ x'e = 0. \end{cases}$$

МНК подбирает коэффициенты $\hat{\beta}_1$ и $\hat{\beta}_2$ так, что длина вектора остатков e минимальна.




$$\sum_{i=1}^n e_i^2 = e'e$$

↑
квадрат длины
вектора e

Геометрическая интерпретация МНК – V: мораль

Вектор прогнозов \hat{y} – ортогональная проекция вектора y на плоскость векторов i и x .

Вектор остатков e – ортогональная проекция вектора y на дополнение к плоскости векторов i и x .



$$\sum_{i=1}^n e_i^2 = e'e$$

↑
квадрат длины
вектора e

МНК для множественной регрессии - I

Объясняемая переменная: Y_i .

Объясняющие переменные: $X_{2,i}, X_{3,i}, \dots, X_{k,i}$.

Имеются данные $(X_{2,1}, X_{3,1}, \dots, X_{k,1}, Y_1), \dots, (X_{2,n}, X_{3,n}, \dots, X_{k,n}, Y_n)$, которые мы желаем представить в виде

$$Y_i = \beta_1 + \beta_2 X_{2,i} + \beta_3 X_{3,i} + \dots + \beta_k X_{k,i} + \varepsilon_i.$$

Задача о наименьших квадратах. Найдите значения β_1, \dots, β_k , при которых сумма квадратов отклонений значений объясняемой величины Y_i от значений линейной функции $\beta_1 + \beta_2 X_{2,i} + \beta_3 X_{3,i} + \dots + \beta_k X_{k,i}$ минимальна.

$$\sum_{i=1}^n \left(Y_i - (\beta_1 + \beta_2 X_{2,i} + \beta_3 X_{3,i} + \dots + \beta_k X_{k,i}) \right)^2 \xrightarrow{\beta_1, \dots, \beta_k} \min.$$


МНК для множественной регрессии - II

Рассмотрим векторы

$$\underset{(n \times 1)}{\underline{y}} = \begin{pmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_n \end{pmatrix}; \quad \underset{(n \times 1)}{\underline{i}} = \begin{pmatrix} 1 \\ 1 \\ \dots \\ 1 \end{pmatrix}; \quad \underset{(n \times 1)}{\underline{x_j}} = \begin{pmatrix} X_{j,1} \\ X_{j,2} \\ \dots \\ X_{j,n} \end{pmatrix}; \quad \underset{(n \times 1)}{\underline{\hat{y}}} = \begin{pmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \dots \\ \hat{Y}_n \end{pmatrix} = \hat{\beta}_1 i + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k;$$

$$\underset{(n \times 1)}{\underline{e}} = y - \hat{y}.$$

МНК подбирает коэффициенты $\hat{\beta}_1, \dots, \hat{\beta}_k$ так, что длина вектора остатков e минимальна \Rightarrow \hat{y} – ортогональная проекция вектора y на пространство векторов i и x_2, \dots, x_k .



$$\begin{cases} i'e = 0; \\ x_2'e = 0; \\ x_3'e = 0; \\ \dots \\ x_k'e = 0. \end{cases}$$

МНК для множественной регрессии - III

Решаем систему:

$$\begin{cases} i'e = 0; \\ x'_2 e = 0; \\ x'_3 e = 0; \\ \dots \\ x'_k e = 0. \end{cases}$$

Пусть $\underbrace{X}_{(n \times k)} = (i \ x_2 \ x_3 \ \dots \ x_k) = \begin{pmatrix} 1 & X_{2,1} & X_{3,1} & \dots & X_{k,1} \\ 1 & X_{2,2} & X_{3,2} & \dots & X_{k,2} \\ 1 & \dots & \dots & \dots & \dots \\ 1 & X_{2,n} & X_{3,n} & \dots & X_{k,n} \end{pmatrix}.$

В матричном виде система (*) записывается так: $X'e = \underbrace{0}_{(k \times 1)}.$

Теперь нужно выразить остатки через коэффициенты регрессии и решить уравнение относительно коэффициентов.

МНК для множественной регрессии – IV

Уравнение регрессии: $Y_i = \beta_1 + \beta_2 X_{2,i} + \beta_3 X_{3,i} + \dots + \beta_k X_{k,i} + \varepsilon_i$.

В векторной записи: $y = \beta_1 i + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$, где $\underset{(n \times 1)}{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{pmatrix}$.

В матричной записи: $y = X\beta + \varepsilon$, где $\underset{(k \times 1)}{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_k \end{pmatrix}$.

Вектор прогнозов: $\hat{y} = \hat{\beta}_1 i + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_k x_k = X\hat{\beta}$, где $\hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \dots \\ \hat{\beta}_k \end{pmatrix}$.

Остатки: $e = y - \hat{y} = y - X\hat{\beta}$.

Условие ортогональности:

$$X'e = 0 \quad \Longleftrightarrow \quad X'(y - X\hat{\beta}) = 0.$$

МНК для множественной регрессии – V

Условие ортогональности:

$$X'e = 0 \quad \Longleftrightarrow \quad X'(y - X\hat{\beta}) = 0.$$

Раскрываем скобки:

$$X'y - X'X\hat{\beta} = 0.$$

Переносим:

$$X'X\hat{\beta} = X'y.$$

Домножаем слева на $(X'X)^{-1}$:

(а что если $(X'X)$ необратима?)

$$(X'X)^{-1}X'X\hat{\beta} = (X'X)^{-1}X'y.$$

Сокращаем:

$$\hat{\beta} = (X'X)^{-1}X'y.$$

Вот и всё.

Подытожим

По данным $(X_{2,1}, X_{3,1}, \dots, X_{k,1}, Y_1), \dots, (X_{2,n}, X_{3,n}, \dots, X_{k,n}, Y_n)$ оценивается регрессия

$$Y_i = \beta_1 + \beta_2 X_{2,i} + \beta_3 X_{3,i} + \dots + \beta_k X_{k,i} + \varepsilon_i.$$

Пусть $\underset{(n \times 1)}{\underbrace{y}} = \begin{pmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_n \end{pmatrix}$, $\underset{(n \times k)}{\underbrace{X}} = \begin{pmatrix} 1 & X_{2,1} & X_{3,1} & \dots & X_{k,1} \\ 1 & X_{2,2} & X_{3,2} & \dots & X_{k,2} \\ 1 & \dots & \dots & \dots & \dots \\ 1 & X_{2,n} & X_{3,n} & \dots & X_{k,n} \end{pmatrix}$, $\underset{(k \times 1)}{\underbrace{\beta}} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_k \end{pmatrix}$, $\underset{(n \times 1)}{\underbrace{\varepsilon}} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{pmatrix}$.

Уравнение регрессии в матричной записи: $y = X\beta + \varepsilon$.

МНК-оценка вектора коэффициентов:

$$\underset{(k \times 1)}{\underbrace{\hat{\beta}}} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \dots \\ \hat{\beta}_k \end{pmatrix} = (X'X)^{-1}X'y.$$

Вектор объясняемой переменной и его проекции

Ортогональная проекция y на пространство регрессоров (линейную оболочку X):


$$\hat{y} = X\hat{\beta} = X \underbrace{(X'X)^{-1}X'y}_{\hat{\beta}} = Py.$$

$P = X(X'X)^{-1}X'$ - матрица оператора ортогонального проецирования на пространство регрессоров (hat matrix).

Ортогональная проекция y на дополнение к пространству регрессоров:

$$e = y - \hat{y} = y - Py = (I - P)y.$$

$(I - P)$ – матрица оператора ортогонального проецирования на дополнение к пространству регрессоров.



Интерпретация коэффициентов в парной и множественной регрессии

Пример. По ежеквартальным данным об экономике США с I квартала 1952 г. по II квартал 1961 г. оценена зависимость конечного потребления C от располагаемого дохода Y и объёма ликвидных активов L :

$$\hat{C} = -10.63 + 0.68Y + 0.37L;$$

$$\hat{C} = -7.16 + 0.95Y.$$

Все переменные в млрд. долл. США 1954 года.

Интерпретация коэффициентов в парной и множественной регрессии

Пример. По ежеквартальным данным об экономике США с I квартала 1952 г. по II квартал 1961 г. оценена зависимость конечного потребления C от располагаемого дохода Y и объёма ликвидных активов L :

$$\hat{C} = -10.63 + 0.68Y + 0.37L;$$

$$\hat{C} = -7.16 + 0.95Y.$$

Все переменные в млрд. долл. США 1954 года.

А теперь зависимость ликвидных активов от дохода:

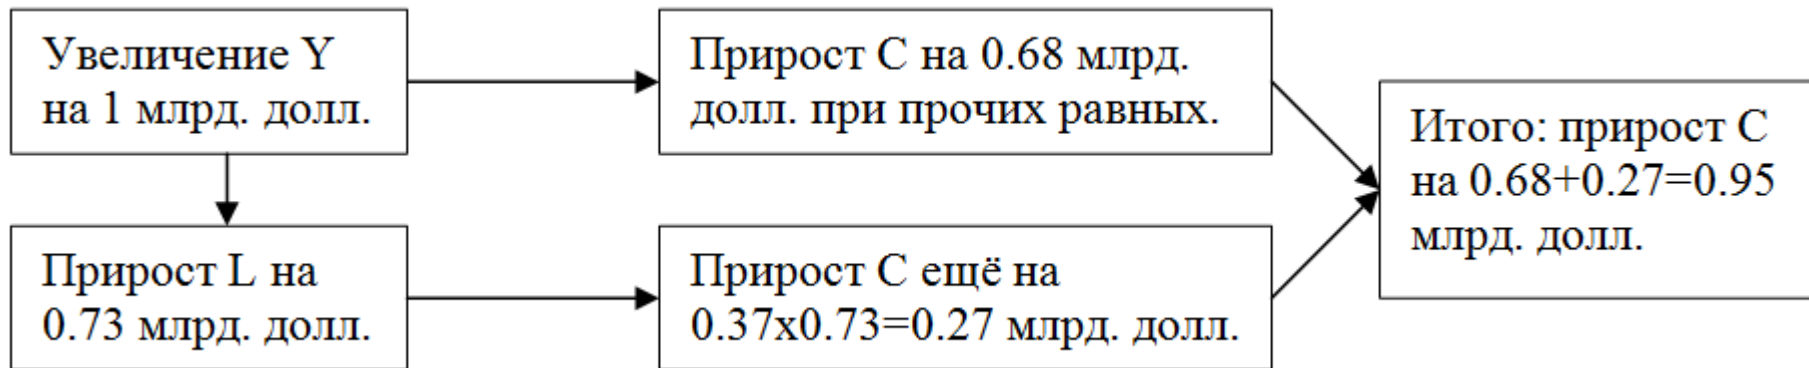
$$\hat{L} = 9.31 + 0.73Y.$$

$$\hat{C} = -10.63 + 0.68Y + 0.37L;$$

$$\hat{C} = -7.16 + 0.95Y;$$

$$\hat{L} = 9.31 + 0.73Y.$$

Можно разделить связь между С и Y на «непосредственную» (при прочих равных условиях) и опосредованную связью обеих переменных с L:



Часть третья: свойства МНК и коэффициент детерминации

Свойства МНК (первая порция):

$$1^\circ \sum_{i=1}^n e_i = 0.$$


$$2^\circ \sum_{i=1}^n X_{j,i} e_i = 0, \quad j = 2, \dots, k.$$

$$3^\circ \sum_{i=1}^n \hat{Y}_i e_i = 0.$$

$$1^\circ i' e = 0.$$

$$2^\circ x'_j e = 0, \quad j = 2, \dots, k.$$

$$3^\circ \hat{y}' e = 0.$$



$$\begin{cases} i' e = 0; \\ x'_2 e = 0; \\ x'_3 e = 0; \\ \dots \\ x'_k e = 0. \end{cases}$$

Свойства МНК (вторая порция)

$$4^\circ \bar{Y} = \bar{\hat{Y}}.$$

Док-во: $\blacktriangleleft \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i + e_i) = \frac{1}{n} \sum_{i=1}^n \hat{Y}_i + \frac{1}{n} \underbrace{\sum_{i=1}^n e_i}_0 = \bar{\hat{Y}}. \blacktriangleright$

Свойства МНК (вторая порция)

$$4^\circ \bar{Y} = \bar{\hat{Y}}.$$

$$\text{Док-во: } \blacktriangleleft \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i + e_i) = \frac{1}{n} \sum_{i=1}^n \hat{Y}_i + \frac{1}{n} \underbrace{\sum_{i=1}^n e_i}_0 = \bar{\hat{Y}}. \blacktriangleright$$

$$5^\circ \bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2 + \dots + \hat{\beta}_k \bar{X}_k.$$

$$\begin{aligned} \text{Док-во: } \blacktriangleleft \bar{Y} = \bar{\hat{Y}} &= \frac{1}{n} \sum_{i=1}^n (\hat{\beta}_1 + \hat{\beta}_2 X_{2,i} + \dots + \hat{\beta}_k X_{k,i}) = \\ &= \frac{1}{n} \left(\underbrace{\sum_{i=1}^n \hat{\beta}_1}_{n\hat{\beta}_1} + \underbrace{\sum_{i=1}^n \hat{\beta}_2 X_{2,i}}_{\hat{\beta}_2 n\bar{X}_2} + \dots + \underbrace{\sum_{i=1}^n \hat{\beta}_k X_{k,i}}_{\hat{\beta}_k n\bar{X}_k} \right) = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2 + \dots + \hat{\beta}_k \bar{X}_k. \blacktriangleright \end{aligned}$$

Свойства МНК (вторая порция)

$$4^\circ \bar{Y} = \bar{\hat{Y}}.$$

$$\text{Док-во: } \blacktriangleleft \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i + e_i) = \frac{1}{n} \sum_{i=1}^n \hat{Y}_i + \frac{1}{n} \underbrace{\sum_{i=1}^n e_i}_0 = \bar{\hat{Y}}. \blacktriangleright$$

$$5^\circ \bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2 + \dots + \hat{\beta}_k \bar{X}_k.$$

$$\begin{aligned} \text{Док-во: } \blacktriangleleft \bar{Y} = \bar{\hat{Y}} &= \frac{1}{n} \sum_{i=1}^n (\hat{\beta}_1 + \hat{\beta}_2 X_{2,i} + \dots + \hat{\beta}_k X_{k,i}) = \\ &= \frac{1}{n} \left(\underbrace{\sum_{i=1}^n \hat{\beta}_1}_{n\hat{\beta}_1} + \underbrace{\sum_{i=1}^n \hat{\beta}_2 X_{2,i}}_{\hat{\beta}_2 n\bar{X}_2} + \dots + \underbrace{\sum_{i=1}^n \hat{\beta}_k X_{k,i}}_{\hat{\beta}_k n\bar{X}_k} \right) = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2 + \dots + \hat{\beta}_k \bar{X}_k. \blacktriangleright \end{aligned}$$

$$\begin{array}{lll} 6^\circ \text{ Введём обозначения:} & TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2 & \text{(Total Sum of Squares)} \\ & ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 & \text{(Explained Sum of Squares)} \\ & RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n e_i^2 & \text{(Residual Sum of Squares)} \end{array}$$

Тогда

$$TSS = ESS + RSS.$$

Коэффициент детерминации

$$TSS = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad (\text{Total Sum of Squares})$$

$$ESS = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \quad (\text{Explained Sum of Squares})$$

$$RSS = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 \quad (\text{Residual Sum of Squares})$$

$$TSS = ESS + RSS$$

Коэффициент детерминации:


$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}.$$

$$0 \leq R^2 \leq 1$$


нет связи объясняемой переменной
с объясняющими ($ESS = 0, \hat{Y}_i = const$)

строгая линейная связь объясняемой
переменной с объясняющими
($RSS = 0$, все остатки равны нулю,
данные идеально описываются уравнением
регрессии)


Коэффициент детерминации - 2




$$R^2 = 0$$



$$R^2 = 0.4$$



$$R^2 = 0.8$$



$$R^2 = 1$$

Множественный коэффициент корреляции

Коэффициент корреляции между Y и прогнозами $\hat{Y} = \hat{\beta}_1 + \hat{\beta}_2 X_2 + \dots + \hat{\beta}_k X_k$ называется множественным коэффициентом корреляции между признаком Y и признаками X_2, \dots, X_k .

$$0 \leq r_{Y, \hat{Y}} \leq 1.$$

Утверждение. $R^2 = r_{Y, \hat{Y}}^2$.

Доказательство.

$$\blacktriangleleft r_{Y, \hat{Y}}^2 = \frac{[\sum_{i=1}^n (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y})]^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2 \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2} = \frac{[\sum_{i=1}^n (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y})]^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2 \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2} = \frac{[\sum_{i=1}^n (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y})]^2}{TSS \cdot ESS}.$$

$$\begin{aligned} \sum_{i=1}^n (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y}) &= \sum_{i=1}^n Y_i \hat{Y}_i - \sum_{i=1}^n Y_i \bar{Y} - \sum_{i=1}^n \bar{Y} \hat{Y}_i + \sum_{i=1}^n \bar{Y}^2 = \\ &= \sum_{i=1}^n (\hat{Y}_i + e_i) \hat{Y}_i - \bar{Y} \underbrace{\sum_{i=1}^n Y_i}_{n\bar{Y}} - \bar{Y} \underbrace{\sum_{i=1}^n \hat{Y}_i}_{n\bar{Y}} + n\bar{Y}^2 = \sum_{i=1}^n \hat{Y}_i^2 + \underbrace{\sum_{i=1}^n e_i \hat{Y}_i}_0 - n\bar{Y}^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = ESS. \end{aligned}$$

Таким образом, $r_{Y, \hat{Y}}^2 = \frac{ESS^2}{TSS \cdot ESS} = \frac{ESS}{TSS} = R^2$. \blacktriangleright

Важно:

- Нет смысла сравнивать R^2 в моделях с разными объясняемыми переменными (например, Y и $\ln Y$).
- R^2 не уменьшается (обычно растёт) при добавлении регрессора.
- R^2 не применим к регрессии без свободного члена

$$Y_i = \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_k X_{k,i} + \varepsilon_i.$$

В этом случае он может выходить за пределы от 0 до 1, не равен квадрату корреляции и лишён обычного смысла.

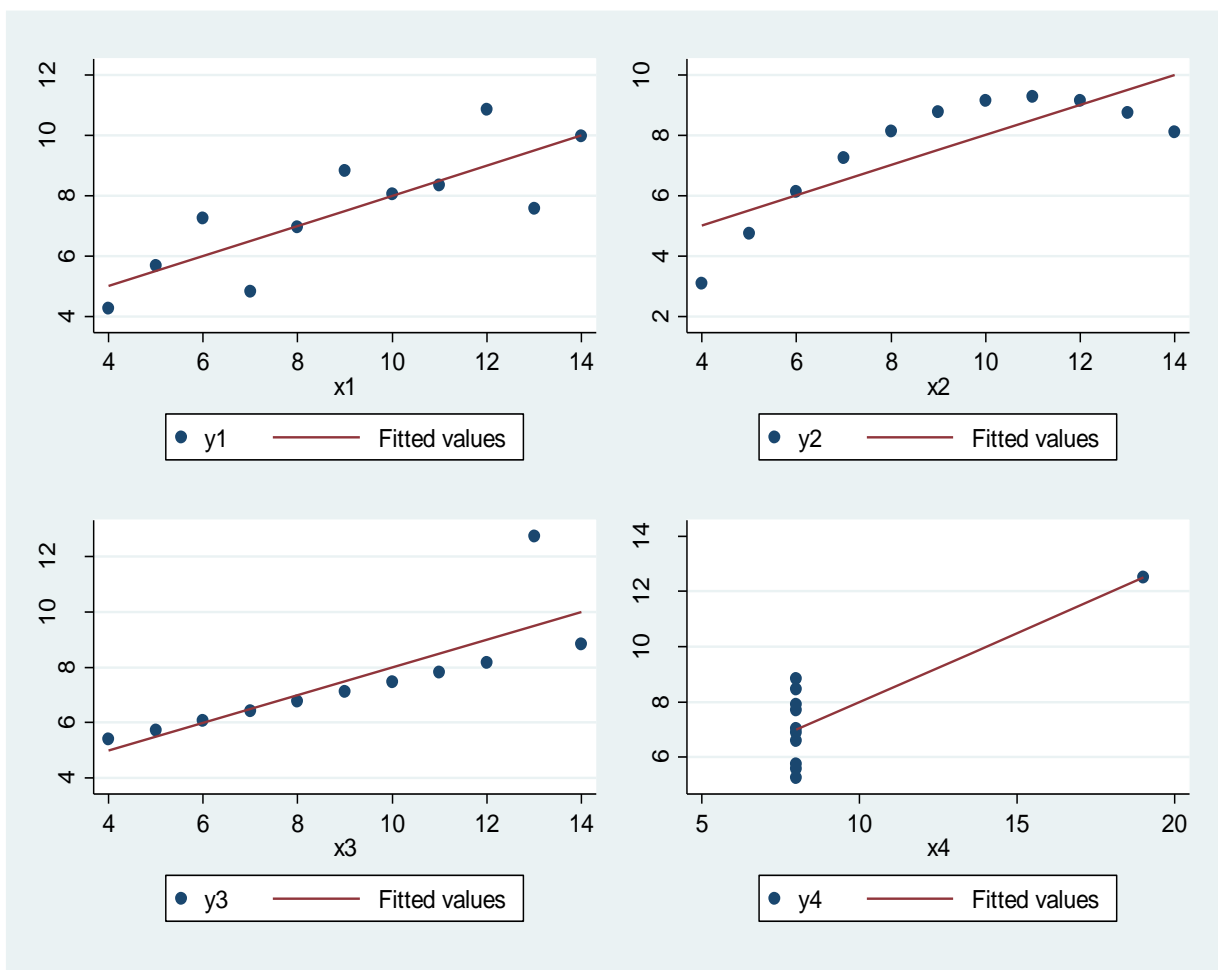
Без свободного члена не выполняется ряд свойств МНК.

В частности, $TSS \neq ESS + RSS$.

Упражнение. Проверьте, какие свойства МНК выполняются для регрессии без свободного члена.

Интерлюдия: квартет Энскомба

F. G. Anscombe (1973), "Graphs in Statistical Analysis".



Во всех четырёх случаях $\hat{Y} = 3 + 0.5X$, $R^2 = 0.67$.

Качественные признаки в уравнении регрессии

Пример. Данные о заработных платах 1472 работников в Бельгии, 1994 год.

Объясняемый признак: $wage_i$, $i = 1, \dots, 1472$, почасовая заработная плата.

Объясняющие:

- $exper_i$ - опыт работы в годах;
- пол;
- уровень образования (пять категорий).

Как учесть пол?

Сделаем так: $male_i = \begin{cases} 1, & \text{работник } i \text{ — мужчина,} \\ 0, & \text{работник } i \text{ — женщина.} \end{cases}$

$$\ln \widehat{wage} = 1.85 + 0.16 \ln(1 + exper) + 0.08 male, \quad R^2 = 0.13.$$

Интерпретация: $male \uparrow$ на 1 при прочих равных $\Rightarrow \ln \widehat{wage} \uparrow$ на 0.08 $\Rightarrow \widehat{wage} \uparrow$ в $e^{0.08} = 1.08$ раз.

Заработная плата мужчины в среднем на 8% выше з/п женщины с тем же опытом работы.

Статистический жаргон: дамми-переменная (dummy variable) – переменная, которая принимает значения 0 или 1, бинарная переменная.

Качественные признаки в уравнении регрессии - II

Как учесть образование?

Можно создать пять дамми-переменных – индикаторов для каждого уровня образования.

$$D1_i = \begin{cases} 1, & \text{у работника } i \text{ первый уровень образования,} \\ 0, & \text{иначе.} \end{cases}$$

$$D2_i = \begin{cases} 1, & \text{у работника } i \text{ второй уровень образования,} \\ 0, & \text{иначе.} \end{cases}$$

...

$$D5_i = \begin{cases} 1, & \text{у работника } i \text{ пятый уровень образования,} \\ 0, & \text{иначе.} \end{cases}$$

Но в уравнение включаются не все переменные, а любые четыре.

Одна категория образования остаётся без переменной. Она называется *базовой категорией*.

Возьмём в качестве базового первый (низший) уровень образования:

$$\widehat{\ln wage} = 1.27 + 0.23 \ln(1 + \text{exper}) + 0.12\text{male} + 0.14D2 + 0.30D3 + 0.47D4 + 0.64D5, \\ R^2 = 0.40.$$

Качественные признаки в уравнении регрессии - III

$$\ln \widehat{wage} = 1.27 + 0.23 \ln(1 + exper) + 0.12male + 0.14D2 + 0.30D3 + 0.47D4 + 0.64D5, \\ R^2 = 0.40.$$

Интерпретация: $D2 \uparrow$ на 1 при прочих равных $\Rightarrow \ln \widehat{wage} \uparrow$ на 0.14 \Rightarrow
 $\Rightarrow \widehat{wage} \uparrow$ в $e^{0.14} = 1.15$ раз.

Заработная плата работника со вторым уровнем образования в среднем на 15% выше з/п работника того же пола и с тем же опытом работы, но с первым уровнем образования.

Т.е. коэффициенты при дамми-переменных отражают отличия выделяемой категории (второй уровень образования) от базовой (первый уровень).

| Уровень образования | Оценённый коэффициент, $\hat{\beta}_j$ | Потенцированный коэфф-т, $e^{\hat{\beta}_j}$ | Прибавка к з/п базовой категории при прочих равных, % |
|---------------------|--|--|---|
| 1 | - | - | 0 |
| 2 | 0.14 | 1.15 | 15% |
| 3 | 0.30 | 1.36 | 36% |
| 4 | 0.47 | 1.61 | 61% |
| 5 | 0.64 | 1.89 | 89% |

В следующий раз:

классическая линейная нормальная регрессионная модель
и оценивание её параметров,

теорема Гаусса-Маркова.